

Thinker 夏目漱石コーパス構築・思想／創作分離 実装指示書 v0.1

0. この指示書の目的

既存のThinkerへ夏目漱石の原典コーパスを導入し、以下を明確に分離して利用できる基盤を構築してください。

1. 漱石本人が直接述べた思想
2. 漱石の創作論・文学論
3. 小説内の語り手の記述
4. 小説内の登場人物の思想・判断
5. 漱石の文体・物語構成・象徴操作
6. 漱石の経歴・体験・時代背景
7. AIが原典から外挿した推論

最初の目的は、夏目漱石についての思想対話と、今後追加するThinker Creativeのための、信頼できるL1コーパスを作ることです。

本指示の範囲は、次までとします。

- ・青空文庫からの作品一覧取得
- ・原典ファイル取得
- ・作品・版の正規化
- ・ルビ・注記等の正規化
- ・文書・チャンクへのタグ付け
- ・用途別Indexの分離
- ・L2思想カード／創作カード候補の抽出
- ・L3判断規則／創作規則候補の抽出
- ・evidence・provenanceの保存
- ・検索ルーティング
- ・データ品質検査
- ・管理画面またはレビュー導線

以下は今回の実装対象外です。

- ・『夢十夜』第十一夜の本生成
- ・『明暗』の続編生成
- ・長編状態管理
- ・推理小説生成
- ・Mystery Truth Graph
- ・fine-tuning
- ・継続事前学習
- ・作家専用モデルの訓練

推理小説用の構想は別資料として管理し、今回のschemaやIndexへ先回りして混ぜないでください。

1. 最重要原則

1.1 既存Thinkerを破壊しない

既存の以下を維持してください。

- L1原典
- L2思想カード
- L3判断規則
- L4判断トレース
- thought_id
- author／thinker routing
- approvedカード必須条件
- approved規則必須条件
- shadow／assist
- Output Guard
- answer_traces
- evidence links
- corpus／self_declared／validated等の承認状態
- 既存API
- 既存管理画面
- 既存テスト

既存schemaを確認せず、本文中の概念名をそのままテーブル名として実装しないでください。

1.2 実装前にリポジトリを監査する

最初の作業はT0リポジトリ監査です。

確認対象：

- 現行のL1文書・チャンクテーブル
- source／document／chunkの関係
- thinker／author／thought_id
- L2カードschema
- L3規則schema
- evidence links
- provenance
- approval status
- embedding provider
- vector DB／全文検索
- reranking

- ingestion pipeline
- parser
- migration規則
- seedデータ
- 管理画面
- evaluation画面
- answer trace
- prompt version管理
- test fixtures
- CI

T0ではコード変更を行わず、現状の正式名称、再利用箇所、衝突点、推奨差分を報告してください。

2. 青空文庫を原典マニフェストとして扱う

夏目漱石の作家別一覧ページを、青空文庫由来コーパスのマニフェストとして扱います。

現行一覧には公開中113件、作業中8件が掲載されています。公開中には同じ作品の新字新仮名・新字旧仮名・旧字旧仮名などの別版が含まれます。

2.1 作業中作品は自動取得しない

`work_status=in_progress` の作品は、通常のproduction corpusへ取り込まないでください。

保存してよいもの：

- 作品ID
- 作品名
- 表記種別
- 作業中であること
- 一覧取得日時

本文取得・Index登録・L2／L3候補生成は行いません。

2.2 公開件数を独立作品数とみなさない

次を分離してください。

```
canonical_work
edition
orthography_variant
source_file
```

例：

```
canonical_work:
  title: 三四郎

editions:
  - aozora_work_id: 58842
    orthography: 新字旧仮名
  - aozora_work_id: 794
    orthography: 新字新仮名
```

同じ本文の版違いを別作品としてembeddingし、検索結果を重複させないでください。

2.3 推奨版

原則として、初期Indexでは読みやすい新字新仮名版を優先します。

ただし、旧字旧仮名版を削除してはいけません。

```
is_primary_retrieval_edition: true / false
```

を持たせ、版比較・文体研究・校訂確認のために保存します。

2.4 青空文庫の利用条件と由来情報

青空文庫は、著作権が切れている作品について、複製・再配布・形式変換・翻案等を認めています。一方で、作品名、著者名、底本、入力者、校正者、作成日、修正日などの由来情報を残すことを希望しています。

したがって、次を削除せずmetadataへ保存してください。

```
bottom_text_title
bottom_text_publisher
bottom_text_publication_date
bottom_text_parent_edition
input_by
proofread_by
aozora_created_at
aozora_updated_at
aozora_notes
copyright_status
license_note
```

本文から青空文庫の奥付部分を除去してembeddingする場合も、元情報はDBへ保存してください。

3. 文書の用途を分離する

全作品を一つのVector Indexへ投入してはいけません。

最低限、次のcorpus roleを持たせます。

```
core_thought
supporting_thought
creative_grammar
character_judgment
narrative_reference
style_reference
biographical_context
validation_only
excluded
```

3.1 core_thought

漱石本人が、講演・評論・論説等で直接述べた判断を抽出するコーパス。

用途：

- L2思想カード
- L3判断規則
- 現代問題への思想的外挿
- 思想回答
- authorial judgment

3.2 supporting_thought

随筆、回想、書簡、談話、序文等。

用途：

- コア思想の例外確認
- 時期による変化
- 個人的体験
- 背景事情
- 用語の意味確認

原則として、単独の短い書簡や談話だけから強いL3規則を確定しないでください。

3.3 creative_grammar

漱石が文学・創作・批評・文体について直接論じた文章。

用途：

- 創作カード
- Narrative Grammar
- Style Rule
- Bridge Rule
- Creative Output Guard
- 作品評価ループリック

3.4 character_judgment

小説内の登場人物の発言・行動・判断。

用途：

- 登場人物ごとの判断規則
- Character State
- Character Judgment
- 人物間の価値観の差
- 『明暗』続編生成

作者本人の思想Indexへは入れません。

3.5 narrative_reference

小説全体の出来事、人物、時系列、関係、象徴、語り、場面。

用途：

- Canon State
- Relationship State
- Narrative Obligation
- 物語構造
- 長編整合性

3.6 style_reference

表層表現の参照用。

用途：

- 文長
- 語彙
- 文末
- 語り手の距離
- 比喩
- 会話比率
- 時代語
- 音・リズム

思想の根拠としては使いません。

3.7 biographical_context

回想、旅行記、学生時代、職歴、病歴、対人関係など。

思想規則の直接根拠ではなく、発言の背景や時期を理解するために使います。

3.8 validation_only

思想カードや規則を作ったあとに、それが小説内でどのように現れるかを検証するコーパス。

カード生成時の入力にはせず、事後検証に使用します。

4. 最初に読み込むコア資料

4.1 Phase A：作者思想の中核

以下を `core_thought` として最優先で取り込んでください。

優先	作品	青空文庫ID	主な抽出対象
A1	私の個人主義	772	自己本位、個性、自由、義務、権力、金力、他者尊重
A2	現代日本の開化	759	内発／外発、近代化、技術、速度、幸福、圧迫
A3	中味と形式	788	内容と形式、分類、単純化、杓子定規の危険
A4	模倣と独立	1747	模倣、学習、外部規範、独立、自己形成
A5	道楽と職業	757	内発的動機、職業化、速度、専門化、外部要求
A6	文芸の哲学的基礎	755	文学経験、評価軸、真・善・美・壮、批評

優先	作品	青空文庫ID	主な抽出対象
A7	文芸と道徳	756	文学と倫理、作品評価、道徳との接触と分離

これらは、青空文庫の公式一覧・本文で公開されています。『中味と形式』は形式化や分類が中味を損なう危険を論じ、『道楽と職業』は専門化・速度・職業化と内発性の緊張を扱っています。『文芸の哲学的基礎』では複数の評価標準を一軸へ還元しない議論が確認できます。

4.2 Phase A：創作・Bridge Ruleの中核

以下を `creative_grammar` として最優先で取り込んでください。

優先	作品	青空文庫ID	主な抽出対象
C1	作家の態度	1102	作者の態度、主観／客観、経験の変形
C2	写生文	796	観察、距離、筋、批評視点、方法の相対化
C3	作物の批評	793	複数評価軸、作品評価、批評方法
C4	高浜虚子著『鶏頭』序	2667	分類、既存ジャンルへの押し込み、創作上の見地
C5	教育と文芸	778	教育、文芸、規範、倫理、創造性

『作家の態度』は、完成作品の表面的分類だけでなく、経験者の態度がどのように創作へ分岐するかを論じています。『写生文』では作品に応じて批評の見地を変える必要が示され、『鶏頭』序では既存の分類へ作品を押し込めることへの留保が確認できます。

4.3 Phase A：青空文庫外の基礎理論

以下は青空文庫の一覧では、全文ではなく序文のみ、または収録対象外です。

優先	作品	取得候補	用途
T1	文学論 全編	国立国会図書館等	文学経験、認識、感情、文学内容の基礎理論
T2	文学評論 全編	国立国会図書館等	文学史、作家・作品比較、批評方法

国立国会図書館には、1907年刊『文学論』と1909年刊『文学評論』の書誌・デジタル資料があります。

ただし、青空文庫取得処理へ直接混ぜないでください。

別source providerとして扱います。

```
source_provider:
  aozora
  ndl
```



```
manual_upload
licensed_source
```

NDL資料については、次を実装前に確認してください。

- 全文テキストとして取得可能か
- 画像のみか
- OCR品質
- 利用条件
- ページと本文の対応
- 引用可能な位置情報
- 版の違い
- 校訂情報

OCR精度が不十分な場合は、低品質本文を自動でL2／L3抽出へ流さず、`needs_manual_review=true`にしてください。

5. Phase B：補助思想・経歴コーパス

Phase Aの後、次を `supporting_thought` または `biographical_context` として追加してください。

自己記述・回想

- 思い出す事など
- 硝子戸の中
- 私の経過した学生時代
- 僕の昔
- 落第

海外体験・近代化

- 倫敦消息
- カーライル博物館
- 満韓ところどころ
- 戦争からきた行き違い

職業・制度・独立

- 入社の辞
- 博士問題とマードック先生と余
- 博士問題の成行
- 文士の生活
- 文芸委員は何をするか

創作自己解説

- ・予の描かんと欲する作品
- ・処女作追懐談
- ・余と万年筆
- ・『文学論』序
- ・『心』自序
- ・『吾輩は猫である』上篇・中篇・下篇自序
- ・各種序文・予告・広告文

書簡

- ・鈴木三重吉宛書簡
- ・その他、権利と出典が明確な書簡

書簡は文脈不足が起こりやすいため、宛先、日付、前後関係を必須metadataとしてください。

6. Phase C：小説コーパス

小説は思想コアとは分離して取り込みます。

優先作品

作品	主用途
吾輩は猫である	観察距離、風刺、人物間の思想衝突
草枕	芸術観、非人情、観察、物語距離
三四郎	近代、地方と都会、知識人の認識
それから	社会批判、自己正当化、代助の人物思想
門	倫理、罪、諦念、宗教的接近
行人	自意識、知性、不安、他者理解
こころ	自己欺瞞、責任、告白、知識非対称
道草	自伝的素材と創作的変換
夢十夜	象徴、夢の論理、説明抑制、終結
明暗	人物別知識、関係状態、外面と内面、長編継続

重要な禁止事項

小説中の登場人物の発言
=
漱石本人の直接思想

として扱ってはいけません。

例：

『それから』における代助の発言

は、原則として、

```
speaker_role=character  
character_id=daisuke  
corpus_role=character_judgment  
authority_level=fictional_indirect
```

です。

漱石本人の思想カードへ昇格させるには、講演・評論・書簡等の直接資料との照合が必要です。

7. 必須metadata

7.1 作品単位

```
document_id  
author_id  
author_name  
canonical_work_id  
canonical_title  
aozora_work_id  
source_provider  
source_url  
card_url  
download_url  
document_genre  
corpus_role  
authority_level
```

```
publication_date
first_publication
historical_period
temporal_phase
language
orthography
edition_variant
bottom_text
parent_edition
work_status
copyright_status
license_note
retrieved_at
content_sha256
parser_version
is_primary_retrieval_edition
duplicate_of
created_at
updated_at
```

7.2 document_genre

最低限：

```
lecture
essay
criticism
literary_theory
preface
afterword
letter
interview
memoir
travelogue
novel
short_story
sketch
advertisement
announcement
other
```

NDCだけでgenreを決定しないでください。

講演・評論・随筆が同じNDC分類に置かれる場合があるため、タイトル、初出、本文冒頭、底本情報を併用します。

7.3 authority_level

```
author_direct  
author_contextual  
fictional_indirect  
third_party  
editorial  
unknown
```

7.4 チャンク単位

```
chunk_id  
document_id  
section_id  
chapter  
subchapter  
paragraph_start  
paragraph_end  
char_start  
char_end  
raw_text  
normalized_text  
speaker_role  
speaker_name  
character_id  
addressee  
claim_type  
assertion_status  
thought_eligibility  
creative_eligibility  
quotation_source  
is_quotation  
is_hypothetical  
is_ironic  
confidence  
classification_reason  
review_status  
reviewed_by  
reviewed_at  
embedding_version
```

7.5 speaker_role

```
author_direct  
narrator  
character  
quoted_person  
interviewer  
editor  
unknown
```

7.6 claim_type

```
normative_claim  
descriptive_observation  
conceptual_distinction  
priority_claim  
prohibition  
exception  
autobiographical_report  
historical_report  
hypothetical_example  
quotation  
literary_analysis  
fictional_statement  
meta_commentary
```

7.7 assertion_status

```
asserted  
attributed  
hypothetical  
questioned  
ironic  
ambiguous  
rejected_by_author
```

8. 青空文庫本文の取得・正規化

8.1 保存する形式

最低限、次を保存してください。

```
raw_bytes
raw_text
normalized_text
display_text
```

- `raw_bytes` : 取得した原ファイル
- `raw_text` : 文字コード変換後、注記を残した本文
- `normalized_text` : 検索・embedding用
- `display_text` : ユーザー表示・引用用

8.2 文字コード

青空文庫の図書カードには、テキストファイルの文字集合・符号化方式が記載されています。作品によってShift_JIS等が使われています。

処理：

1. HTTP headerだけに依存せず文字コードを判定
2. raw bytesを保存
3. UTF-8へ変換
4. 変換エラーを記録
5. 文字化け率を検査
6. 閾値を超えた場合はIndex登録しない

8.3 ルビ

青空文庫形式のルビを解析し、次を分けて保存してください。

```
surface_text
reading
```

embedding用本文では、原則として本文の漢字を残します。

読みはmetadataまたは補助fieldとして保存し、本文へ重複挿入しないでください。

8.4 外字・注記

[# ...] 等の注記を単純削除しないでください。

分類：

```
formatting_note
gaiji_note
editorial_note
original_text_note
ruby_note
emphasis_note
page_note
```

本文理解に不要なレイアウト注記はembeddingから除外してよいですが、原情報として保存します。

8.5 ヘッダ・フッタ

次を本文チャンクへ混ぜないでください。

- 青空文庫作成ファイルの説明
- 入力者・校正者
- 底本情報
- 表記について
- HTML navigation
- 目次リンク

ただしmetadataへ保存します。

8.6 チャンク分割

固定文字数だけで切らないでください。

優先順位：

1. 章
2. 節
3. 段落
4. 話者交代
5. 意味段落
6. token上限

講演・評論：

- 一つの主張
- 具体例
- 反論
- 例外
- 結論

を可能な限り別チャンクにします。

小説：

- 語り手記述
- 人物発言
- 人物行動
- 場面転換

を識別できるようにします。

8.7 重複検出

版違いについて、

- 文字列類似
- 正規化後hash
- 段落対応
- canonical title
- 青空文庫作品ID
- 版metadata

を用いて重複を検出します。

旧字版と新字版は別editionとして保存しつつ、通常検索では同じ段落を複数返さないでください。

9. タグ付け手順

Pass 1：決定的metadata

ルールベースで付与：

- 作品ID
- タイトル
- 版
- 表記

- 公開／作業中
- 初出
- 底本
- source provider
- document genre候補
- corpus role候補

Pass 2：LLMによるチャンク分類

LLMへ次を出力させます。

```
speaker_role
speaker_name
claim_type
assertion_status
thought_eligibility
creative_eligibility
confidence
classification_reason
```

分類理由は短く保存します。

Pass 3：機械的整合性検査

例：

- speaker_role=character なのに document_genre=lecture
- thought_eligibility=core なのに is_quotation=true
- author_direct なのに会話括弧内で人物名が明示
- core_thought なのに小説Index由来
- section情報が欠落
- evidence位置が本文範囲外

を検出します。

Pass 4：人手レビュー

優先レビュー対象：

- confidenceが低い
- 作者と人物の区別が曖昧
- 皮肉
- 引用
- 仮定例

- 講演中の逸話
- 思想規則候補
- Bridge Rule候補
- 反対証拠がある
- 時期によって主張が変わる

LLM分類だけで `approved` にしないでください。

10. Index設計

物理的に別Vector Collectionへ分けるか、共通Collection＋厳格なmetadata filterにするかは、現行インフラを監査して決めてください。

ただし論理的には必ず分離します。

```
author_thought_core_index
author_thought_support_index
creative_grammar_index
character_judgment_index
narrative_reference_index
style_reference_index
biographical_context_index
validation_only_index
```

10.1 思想質問

例：

漱石は生成AIをどう考えるか

検索順：

1. author_thought_core
2. author_thought_support
3. creative_grammar（必要な場合のみ）
4. fictional_indirect（比較・補助として明示）

小説を検索する場合は、回答中で、

作者本人の直接発言ではなく、
作品内人物の発言または物語上の表現である

と区別できるようにします。

10.2 創作質問

例：

『夢十夜』の第十一夜を書け

検索順：

1. creative_grammar
2. narrative_reference: 夢十夜
3. style_reference: 夢十夜および指定範囲
4. author_thought_core: Bridge Ruleを介する場合のみ

思想チャンクをそのまま登場人物の台詞へ注入しないでください。

10.3 人物質問

例：

代助は近代化をどう考えるか

検索順：

1. character_judgment: daisuke
2. narrative_reference: それから
3. author_thought_core: 比較対象としてののみ

11. L2カード候補の抽出

11.1 思想カード

原則として、`author_direct` かつ `thought_eligibility=candidate` のチャンクから作ります。

推奨フィールド：

```
card_id
thinker_id
domain
title
summary
claim
concepts
distinctions
priorities
prohibitions
exceptions
temporal_scope
evidence_links
counter_evidence_links
source_roles
origin_type
confidence
status
version
reviewed_by
reviewed_at
```

11.2 創作カード

```
card_type:
  style
  narrative
  motif
  character
  perspective
  ending
  criticism
  prohibition
```

創作カードの根拠は、創作論・評論と小説本文を区別して保存します。

```
evidence_type:
  author_creative_theory
  demonstrated_in_fiction
  critic_interpretation
```

11.3 承認

```
candidate
reviewing
approved
rejected
deprecated
```

`approved` 以外をassist生成へ使わないでください。

12. L3規則候補の抽出

既存Thinkerの規則型を維持します。

候補：

```
value_transformation
distinction
priority
contradiction_hold
boundary
exception
prohibition
question_rule
abstention
temporal_override
```

推奨フィールド：

```
rule_id
rule_family_id
domain
title
rule_type
trigger
premises
operation
derived_effects
priority
exceptions
prohibited_inferences
```

```
requires_rule_ids
blocks_rule_ids
evidence_links
counter_evidence_links
temporal_scope
source_role_requirements
confidence
status
schema_version
```

12.1 規則の根拠基準

強い規則として承認する条件の例：

- 複数の作者直接資料で確認
- 一つの資料でも極めて明示的
- 反対例・例外を確認
- 時期を確認
- 小説人物の発言だけに依存していない
- システムの一般常識を混入していない

12.2 Bridge Rule

思想と創作の接続規則を、通常の実験規則・創作規則とは別scopeで管理します。

```
rule_scope=bridge_rule
```

例：

```
authorial_thought:
外形と内面を区別する

creative_context:
夫婦関係を描く場面

operation:
表面的な会話と人物の内的反応をずらす

forbidden:
登場人物に作者思想を直接説明させる
```

Bridge Ruleは自動承認しません。

13. 回答時の推論表示

現代の未知質問へ答える場合、次を区別してtraceへ残します。

```
direct_source
retrieved_claim
activated_rule
rejected_rule
system_inference
confidence
abstention_reason
```

例：

```
漱石が生成AIを直接論じた原典：
なし

類推に使用した規則：
技術的効率化と精神的余裕は同一ではない

外挿：
生成AIによる時間短縮が、
自動的に知性向上を意味するとは限らない

確信度：
中

留保：
本人が現代AIを直接評価したものではない
```

Humanitext Aozora型の滑らかなペルソナ回答で起こり得る、

- 作者と登場人物の混同
- 原典とAI推論の混同
- 批判的チャंकへの検索偏り
- 文体の類似による思想的一致の代替
- 不確実な問いへの断定

を防ぐことが目的です。

14. テスト要件

14.1 Parser Unit Tests

- 青空文庫ヘッダ除去
- 奥付抽出
- Shift_JIS等からUTF-8変換
- ルビ解析
- 外字注記
- 傍点・強調
- 章見出し
- 会話文
- 語り手文
- 青空文庫奥付の非embedding
- raw text保持

14.2 Dedup Tests

- 『三四郎』の版違いを同じcanonical workへ統合
- 『それから』の版違いを統合
- 『門』の版違いを統合
- 『吾輩は猫である』の版違いを統合
- 通常検索で同内容を重複表示しない
- 版指定時には個別取得できる

14.3 Role Classification Tests

- 講演の作者直接発言
- 講演中の他者引用
- 小説の語り手
- 小説の登場人物
- 書簡
- インタビュー回答
- 序文
- 仮定例
- 皮肉
- 引用内引用

14.4 Retrieval Tests

ケース1

質問：

漱石は近代化をどう考えたか

期待：

- 『現代日本の開化』等を優先
- 小説中の人物発言を主根拠にしない

ケース2

質問：

代助は日本社会をどう考えたか

期待：

- 『それから』の代助を取得
- 漱石本人の直接思想と区別

ケース3

質問：

漱石は生成AIをどう考えるか

期待：

- 直接原典がないことを表示
- 適用したL3規則を表示
- 推論と原典を分離
- 断定しすぎない

ケース4

質問：

『夢十夜』の第十一夜を書け

期待：

- creative_grammarと夢十夜本文を取得
- author_thought_coreを直接台詞化しない
- 小説人物の発言を作者思想にしない

14.5 Approval Tests

- candidateカードはassistへ入らない
- rejectedカードは検索候補から除外
- approvedのみ本番利用
- version変更時に過去traceが再現可能
- evidence切れのカードを検出

14.6 Data Quality Tests

- 全公開作品マニフェスト取得
- 作業中作品は本文未取得
- orphan chunkなし
- source URL欠落なし
- content hash保存
- parser version保存
- 文字化け率
- 重複率
- speaker_role未分類率
- core thought内のfiction混入率
- evidence span整合性

15. 受入条件

以下をすべて満たした場合、漱石コーパス構築v0.1完了とします。

1. 現行の青空文庫公開作品一覧をマニフェスト化できる
2. 作業中作品をproduction corpusへ入れない
3. 版違いをcanonical workへ統合できる
4. raw、normalized、display textを保存できる
5. 青空文庫の由来情報を保持できる
6. 文書単位のgenre／corpus roleを付けられる
7. チャンク単位のspeaker roleを付けられる
8. 作者・語り手・登場人物・引用人物を区別できる
9. core thought Indexへ小説人物の発言が混入しない
10. 主要12資料を取り込める
11. 『文学論』『文学評論』を別providerとして管理できる
12. approvedカード・規則のみassistで使用する
13. L2／L3の全項目にevidenceとprovenanceがある
14. 原典とAI外挿をtrace上で区別できる
15. 思想検索と創作検索のルーティングを分離できる
16. 既存Thinkerのテストがすべて通る
17. migrationがadditiveでrollback可能
18. corpus snapshotを再現できる

- 19. parser／embedding／promptのversionを保存できる
 - 20. データ品質レポートを出力できる
-

16. 実装フェーズ

T0：リポジトリ監査

成果物：

- 現行schema
- ingestion構造
- 再利用可能箇所
- 衝突点
- 推奨方針
- 関連ファイル一覧
- migrationリスク

コード変更は行わない。

T1：コーパス仕様正本

成果物：

- source model
- canonical work／edition model
- metadata定義
- tag辞書
- Index設計
- routing設計
- approval flow
- ER図
- sequence図

T2：青空文庫Manifest Importer

- 作家別一覧取得
- 公開／作業中判定
- 図書カード取得
- file link取得
- edition正規化
- rights／bottom text metadata

T3 : Parser • Normalizer

- encoding
- ruby
- gaiji
- notes
- header／footer
- chapter
- paragraph
- dialogue
- raw保存
- hash

T4 : Document／Chunk Tagger

- deterministic tag
- LLM tag
- confidence
- review queue
- manual correction
- tag versioning

T5 : Phase Aコーパス投入

- core thought 7資料
- creative grammar 5資料
- 文学論／文学評論provider準備
- Index作成
- retrieval test

T6 : L2／L3候補生成

- 思想カード候補
- 創作カード候補
- 判断規則候補
- Bridge Rule候補
- evidence
- counter evidence
- approval UI

T7 : Router • Trace

- thought query
- character query
- creative query
- source role filter

- inference trace
- abstention
- Output Guard連携

T8：テスト・ドキュメント・snapshot

- unit
- integration
- regression
- data quality
- corpus manifest
- source list
- parser version
- embedding version
- migration docs
- operational docs

17. Claudeの最初の回答で提出するもの

最初からコードを書かず、次を提出してください。

1. 現行Thinkerのリポジトリ監査結果
2. 現行L1／L2／L3／L4との対応
3. 再利用可能なテーブル・service・画面
4. 追加が必要なschema
5. canonical work／editionの管理案
6. 青空文庫Importerの設計
7. parser／normalizerの設計
8. document／chunk tagsの確定案
9. Index分離案
10. query routing案
11. L2／L3抽出フロー
12. approvalフロー
13. migration方針
14. T0～T8の詳細タスク
15. テスト計画
16. 不明点
17. 実コードから確認できなかった事項
18. 今回実装しない事項

設計が正本化されるまで、production migrationや大量取り込みは開始しないでください。

18. 最終原則

- 青空文庫の一覧件数を独立作品数とみなさない
- 作品と版を分ける
- NDCだけで文書種別を決めない
- 文書単位だけでなくチャンク単位でタグを付ける
- 作者・語り手・人物・引用者を分ける
- 小説人物の発言を作者思想へ自動昇格させない
- 原典とAIの外挿を分ける
- 思想カードと創作カードを分ける
- 判断規則と創作規則を分ける
- 両者の連携はBridge Ruleとして明示する
- 未承認カード・規則をassistで使わない
- 原典の出典、底本、版、取得日、hashを保持する
- 発火だけでなく棄却理由も記録する
- 直接資料がない現代質問では留保する
- 文体の似ている回答を思想的な一致とみなさない
- 推理小説用の構造を今回の実装へ混ぜない